

Transfer Öğrenme ve Derin Öğrenme Modelleri ile Araç Görsellerinden Yakıt Tüketimi Tahmini

Ramazan TOKLU

Mehmet Ali BİLİCİ

Ayman El KHADER

Bilgisayar Mühendisliği Bölümü

Kahramanmaraş Sütçü İmam Üniversitesi

Kahramanmaraş/Türkiye

barisbilici12@gmail.com ramazantoklu7@gmail.com Aymanepro38@gmail.com

December 21, 2024

Özetçe: Bu çalışmada, araç görsellerinden yakıt tüketim değerlerini tahmin etmek için yapay zeka tabanlı bir yöntem geliştirilmiştir. Araç seçiminde çevresel ve ekonomik faktörleri dikkate alarak kullanıcıları bilinçlendirmek hedeflenmiştir. Çalışmada, 30 farklı araç modeline ait 2970 görsel ve FuelConsumptionCO2 veri setinden alınan marka, model ve yakıt tüketimi (fuelConsumptionComb) bilgileri kullanılmıştır. Görseller ve yakıt tüketim verileri kullanılarak transfer öğrenme (VGG16, MobileNetV2) ve özel tasarlanan CNN modelleriyle analiz yapılmıştır. Model performansları, MSE, RMSE ve R^2 gibi metriklerle değerlendirilmiş, transfer öğrenme tabanlı modellerin hızlı ve etkili, özel CNN modelinin ise daha uyumlu sonuçlar ürettiği gözlemlenmiştir.

Anahtar Kelimeler: Araç Görselleri, Yakıt Tüketimi Tahmini, Yapay Zeka, Derin Öğrenme, CNN, Transfer Öğrenme.

Abstract: In this study, an artificial intelligence-based solution was developed to estimate fuel consumption from vehicle images. Prediction models

were created using deep learning architectures, including VGG16, MobileNetV2, and a custom CNN model. A total of 2970 images from 30 vehicle models were combined with the FuelConsumptionCO2 dataset. Transfer learning and the custom CNN models were compared, and their performance was evaluated using MSE, RMSE, and R^2 metrics. While transfer learning-based models provided fast and effective results, the custom CNN model exhibited better adaptation to the dataset. This study demonstrated that fuel consumption estimation can be performed solely from images, contributing to environmental and economic awareness.

Keywords: Vehicle Images, Fuel Consumption Estimation, Artificial Intelligence, Deep Learning, Transfer Learning, Performance Metrics.

1 GİRİŞ

Enerji verimliliği ve çevresel sürdürülebilirlik, günümüz otomotiv endüstrisinin en kritik öncelikleri arasındadır. Araçların yakıt tüketimi, ekonomik tasarrufun yanı sıra karbon emisyonlarının azaltılması ve çevresel etkilerin hafifletilmesi bakımından

büyük bir önem taşımaktadır. Ancak, geleneksel yakıt tüketimi tahmin yöntemleri, fiziksel ölçüm ve mühendislik analizlerine dayandığı için zaman alıcı ve maliyetli süreçler içermektedir. Bu durum, daha hızlı, düşük maliyetli ve yenilikçi çözümlere olan ihtiyacı ortaya çıkarmaktadır.

Yapay zeka ve derin öğrenme teknolojileri, büyük veri setleri üzerinde yüksek doğruluk oranlarıyla hızlı tahminler yapabilme yetenekleri sayesinde bu tür sorunlara etkili çözümler sunmaktadır. Özellikle görsel verilerden bilgi çıkarma konusundaki başarıları, araç görsellerine dayalı tahmin modellerinin geliştirilmesi için umut vadetmektedir. Bu bağlamda, araçların görsellerine dayanarak yakıt tüketimini tahmin edebilmek, hem sektörel yenilikler hem de çevresel ve ekonomik farkındalık oluşturma açısından büyük bir potansiyele sahiptir.

Bu çalışmada, araç görsellerinden yakıt tüketimi tahmini yapmayı amaçlayan bir yapay zeka modeli geliştirilmiştir. Çalışma kapsamında, 30 farklı araç modeline ait toplam 2.970 görüntüden oluşan bir veri seti hazırlanmıştır. Araç görselleri, modele giriş olarak kullanılırken, yakıt tüketim verileri FuelConsumptionCO2 veri setinden alınmıştır. Görseller, veri işleme adımlarında normalize edilmiş ve transfer öğrenme tabanlı VGG16 ve MobileNetV2 modelleriyle işlenmiştir. Ayrıca, sıfırdan tasarlanmış bir Convolutional Neural Network (CNN) modeli geliştirilerek farklı yöntemlerin performansı karşılaştırılmıştır.

Bu çalışma, yalnızca araç görsellerine dayanarak yakıt tüketimi tahmini gerçekleştiren ilk uygulamalardan biridir ve literatürdeki önemli bir boşluğu doldurmaktadır. Önerilen yöntem, araç alıcılarının çevresel ve ekonomik açıdan daha bilinçli kararlar almasına katkı sağlamayı hedeflerken, otomotiv sektörü için yenilikçi bir çözüm sunmaktadır.

2 LİTERATÜR ÖZETİ

Dhanalaxmi (2021) Bu çalışma, ağır araçlarda yakıt tüketimini optimize etmek amacıyla sabit mesafe tabanlı bir yapay sinir ağı (ANN) modeli geliştirmiştir. Model, 1 km'lik sabit pencerelerde toplanan yedi farklı parametre (örneğin, durma sayısı, durma

süresi, ortalama hız, ivme) kullanılarak yakıt tüketimini %4 hata oranıyla tahmin etmiştir. Çalışmada ANN kullanılarak %86 doğruluk oranına ulaşılmış ve sürüş profiline duyarlı bir tahmin sağlanmıştır. Bu yöntem, araçların çevresel ve sürüş koşullarına bağlı olarak yakıt tüketimi optimizasyonuna önemli katkılar sunmaktadır. Hamed, Khafagy ve Badry (2021) Araştırmacılar, yakıt tüketimi tahmini için Destek Vektör Makineleri (SVM) kullanarak yüksek doğruluk oranına sahip bir model geliştirmiştir. Kütle Hava Akışı (MAF), Araç Hızı (VS), Devir Sayısı (RPM) ve Gaz Kelebeği Pozisyon Sensörü (TPS) gibi özellikler kullanılarak iki temel denklem (VS_MAF ve RPM_TPS tabanlı) önerilmiştir. Model, R^2 metriği ile değerlendirilmiş ve %97 doğruluk oranı elde edilmiştir. Bu çalışma, dikkatli bir özellik seçimi ve ağırlıklandırma yöntemiyle yakıt tüketimi tahmininde literatüre önemli bir katkı yapmıştır. Prewitt Kenar Tespiti ve İBGYYSA ile Araç Marka ve Model Tanıma Bu çalışmada, araç marka ve modeli tanımak için görüntü işleme teknikleri ve yapay sinir ağları kullanılmıştır. Sistem, Prewitt kenar tespiti yöntemiyle görsellerden kenar noktalarını çıkararak ileri beslemeli geri yayımlı yapay sinir ağları (İBGYYSA) ile işlenmiştir. Test sonuçlarında Toyota Corolla, Volkswagen Passat ve Renault Megane gibi modeller için tanıma oranlarının sırasıyla %99.5, %99.8 ve %98.3 olduğu görülmüştür. Çalışma, düşük işlemci ve bellek ihtiyacı ile platform bağımsız bir araç tanıma yöntemi sunmuştur. Faster R-CNN ResNet50 ile Araç Marka ve Model Sınıflandırması Araç marka ve model sınıflandırması için derin öğrenme yöntemlerinin kullanıldığı bu çalışmada, Faster R-CNN ResNet50, Faster R-CNN ResNet101, R-FCN ResNet101 ve SSD MobileNet gibi modeller eğitilmiştir. 10 farklı araç modeli ve yaklaşık 20.000 görüntü içeren veri seti ile gerçekleştirilen çalışmada, Faster R-CNN ResNet50 modeli %94.4 doğruluk oranıyla en iyi sonucu vermiştir. TensorFlow ve Python kullanılarak gerçekleştirilen bu çalışma, derin öğrenme tabanlı araç sınıflandırma yöntemlerinin etkinliğini ortaya koymaktadır.

3 VERİ SETİ VE YÖNTEM

3.1 VERİ SETİ

Bu çalışmada iki farklı veri seti kullanılmıştır. İlk veri seti olan *FuelConsumptionCO2*, araçların yakıt tüketimi ve çevresel etkileriyle ilgili veriler içermektedir. İkinci veri seti ise araç görsellerinden oluşmaktadır. Bu kapsamda, 30 farklı araç modeli seçilmiş ve bu modeller için toplamda 2970 adet görsel manuel olarak toplanmıştır. Bu görseller, model eğitiminde görsel tabanlı tahminler yapmak için kullanılmıştır.

3.1.1 Veri Setlerinin Hazırlanması

Veri setlerinin hazırlanması sırasında aşağıdaki adımlar gerçekleştirilmiştir:

FuelConsumptionCO2 Veri Seti

- Veri setinden araç markaları, modelleri ve kombine yakıt tüketimi bilgileri çıkarılmıştır.
- Bu bilgiler, yakıt tüketimi tahminleri için temel girdi olarak kullanılmıştır.

Araç Görselleri Veri Seti

- Her bir araç modeli için farklı açılardan görseller toplanmıştır.

3.1.2 Veri Setlerinin Birleştirilmesi

İki veri seti kod ile birleştirilerek ortak bir analiz tabanı oluşturulmuştur. Araç görselleri ve yakıt tüketim verileri, araç modelleri üzerinden eşleştirilmiş ve tek bir veri tabanı haline getirilmiştir. Bu birleştirme işlemi, veri uyumluluğunu artırmak ve model performansını iyileştirmek için gerçekleştirilmiştir.

3.1.3 Veri Setlerinin Bölünmesi

Her iki veri seti de eğitim, doğrulama ve test amaçlı olarak aşağıdaki şekilde bölünmüştür:

- **Eğitim Seti:** Toplam verilerin %80'i eğitim için kullanılmıştır.
- **Doğrulama Seti:** Eğitim verilerinin %20'si doğrulama amaçlı ayrılmıştır.

- **Test Seti:** Toplam verilerin %20'si model performansını değerlendirmek için test setine ayrılmıştır.

Bu yapılandırma, modellerin farklı veri alt grupları üzerindeki performansını doğru bir şekilde değerlendirmek ve aşırı öğrenme eğilimlerini azaltmak için tasarlanmıştır. İki veri setinin birleştirilmesiyle zengin ve çeşitli bir veri tabanı oluşturulmuş ve modellerin genel başarı oranı artırılmıştır.

3.2 YÖNTEM

Bu çalışma, yapay zeka tabanlı bir yakıt tüketimi tahmin sistemi geliştirmek amacıyla deneysel bir tasarımla gerçekleştirilmiştir. Araç görsellerinden yakıt tüketim değerlerini tahmin etmek için üç farklı derin öğrenme mimarisi (VGG16, MobileNetV2 ve özel olarak tasarlanmış bir CNN modeli) kullanılmıştır.

Araştırmanın temel hedefi, transfer öğrenme tabanlı modeller ile sıfırdan tasarlanan bir CNN modelinin performans farklılıklarını ortaya koymaktır. Bu tasarımla, modellerin yakıt tüketim değerlerini performans metrikleriyle tahmin etme kabiliyeti incelenmiştir.

3.2.1 Veri Toplama

- Araç görselleri manuel olarak internet üzerinden toplanmış ve toplamda 2970 görselden oluşan özel bir veri seti oluşturulmuştur. Bu veri seti, 30 farklı araç modelini kapsamaktadır.
- Yakıt tüketim verileri ise FuelConsumptionCO2 veri setinden sağlanmıştır (Kaggle platformu).

3.2.2 Veri Entegrasyonu

Toplanan görseller ile yakıt tüketim verileri birleştirilerek her bir görselin yakıt tüketim bilgisi ile ilişkisi tanımlanmıştır. Veri seti ön işleme adımlarından geçirilmiş, boyutlar standart hale getirilmiş ve model girişine uygun bir yapıya dönüştürülmüştür.

3.2.3 Veri Analizi

- **Transfer Öğrenme Modelleri:** VGG16 ve MobileNetV2 modelleri, önceden eğitilmiş ağırlıkları kullanılarak tahmin problemi için yeniden uyarlanmıştır. Bu modeller, görsel analizi hızlı ve etkili bir şekilde gerçekleştirme potansiyeline sahiptir.
- **CNN Modeli:** Sıfırdan tasarlanan bir CNN modeli, veri setine özel olarak optimize edilmiş ve transfer öğrenme modelleriyle performansı karşılaştırılmıştır. Çözümlemelerde bu modelin veri setine uyum kapasitesi detaylı olarak analiz edilmiştir.

3.2.4 Performans Metrikleri

Modellerin başarısı, aşağıdaki metrikler kullanılarak değerlendirilmiştir:

- **Mean Absolute Error (MAE):** Ortalama mutlak hata, modellerin tahminlerinin hedef değerlere yakınlığını ifade eder. MAE'nin formülü, Formül (1) ile gösterilmiştir.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (1)$$

- **Mean Squared Error (MSE):** Ortalama kare hata, hata oranlarını kareleyerek daha hassas bir ölçüm sağlar. MSE'nin formülü, Formül (2) ile verilmiştir.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2)$$

- **Root Mean Squared Error (RMSE):** Kök ortalama kare hata, tahmin performansını değerlendirmek için kullanılan yaygın bir metriktir. RMSE'nin formülü, Formül (3) ile gösterilmiştir.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3)$$

- **R² (Açıklanan Değişkenlik Katsayısı):** Modelin toplam değişkenlik üzerindeki açıklayabilme kapasitesini ifade eder. R²'nin formülü, Formül (4) ile verilmiştir.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (4)$$

Performans değerlendirmeleri tablo halinde sunulmuş ve modellerin başarı farklılıkları net bir şekilde ortaya konmuştur.

3.2.5 Analiz Araçları

- Veri işleme ve model eğitimi için **Python** programlama dili ve **Keras** kütüphanesi tercih edilmiştir.
- Görsel analiz ve metrik hesaplamalarında **NumPy**, **Pandas** ve **Matplotlib** kütüphaneleri aktif olarak kullanılmıştır.

4 BULGULAR

Bu çalışmada, araç görsellerinden yakıt tüketimini tahmin etmek amacıyla Kaggle platformundan elde edilen FuelConsumptionCO2 veri seti [1] ile manuel olarak oluşturulan özel bir veri seti kullanılmıştır. Farklı makine öğrenimi modellerinin araç yakıt tüketimi tahmin performanslarını değerlendirmek için kapsamlı bir analiz gerçekleştirilmiştir. Bu analizde, üç farklı derin öğrenme mimarisi (VGG16, MobileNetV2 ve mimarisi oluşturulmuş bir CNN modeli) kullanılmıştır. Aşağıda, her bir modelin çeşitli performans metriklerine göre elde ettiği sonuçlar detaylı bir şekilde sunulmaktadır.

4.1 CNN Modeli

Bu çalışmada, Convolutional Neural Network (CNN) modelinin performansı dört temel metrikle değerlendirilmiştir: Ortalama Mutlak Hata (MAE), Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE) ve R². Modelin MAE değeri 0.4504, MSE değeri 4.0386, RMSE değeri 2.0096 ve R² değeri

0.6074 olarak bulunmuştur. Bu sonuçlar, modelin tahminlerinin genel olarak doğru olduğunu ancak doğruluğun iyileştirilebileceğini göstermektedir. Sonuçlar, aşağıda tablo[1]'de özetlenmiştir.

Performans Metrikleri	Değerler
MAE	0.4504
MSE	4.0386
RMSE	2.0096
R^2	0.6074

Table 1: CNN Modelinin Performans Metrikleri

Şekil [1], modelin eğitim ve doğrulama veri setleri üzerindeki kayıp (loss) değerlerini göstermektedir. Grafik, modelin öğrenme sürecindeki performansını değerlendirmek için önemli bilgiler sunmaktadır.




Figure 1: Kayıp Eğrileri

Eğitim kaybı (mavi eğri), modelin eğitim verisi üzerindeki hatasını temsil ederken, doğrulama kaybı (turuncu eğri) modelin doğrulama verisi üzerindeki hatasını göstermektedir. Grafik incelendiğinde şu gözlemler yapılmıştır:

- **Başlangıç Dönemi (Epoch 0-2)** Eğitim ve doğrulama kaybı başlangıçta yüksektir (yaklaşık 1.2). Ancak her iki kayıp değeri de hızla azalmaktadır. Bu, modelin veri setindeki temel yapıları öğrenmeye başladığını göstermektedir.
- **Orta Dönem (Epoch 3-10)** Eğitim kaybı sürekli olarak düşerken, doğrulama kaybı daha

az bir hızla azalmaktadır. Bu aşamada model, doğrulama verisinde daha az düzenli bir performans göstermiştir; ancak genel eğilim olumlu yöndedir.

- **Son Dönem (Epoch 10-20)** Eğitim kaybı sürekli azalmaya devam ederken, doğrulama kaybı belirli bir noktada sabitlenmiştir. Eğitim kaybı doğrulama kaybından daha düşük bir değere ulaşmıştır. Bu durum, modelin doğrulama verisi üzerindeki öğrenme sınırına yaklaştığını göstermektedir. Ancak iki kayıp arasında büyük bir fark bulunmaması, modelin aşırı öğrenim (overfitting) yapmadığını ortaya koymaktadır.

Grafik, modelin eğitim ve doğrulama veri setleri üzerindeki performansını başarılı bir şekilde değerlendirdiğini ve uygun bir genel doğruluk elde ettiğini göstermektedir.

4.2 VGG16 Modeli

Bu çalışmada, VGG16 modeli kullanılarak Modelin değerlendirilmesi için Ortalama Mutlak Hata (MAE), Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE) ve Determinasyon Katsayısı (R^2) gibi performans metrikleri hesaplanmıştır. Modelin MAE değeri 0.4346, MSE değeri 3.777, RMSE değeri 1.9434 ve R^2 değeri 0.6328 olarak bulunmuştur. Bu sonuçlar, modelin tahminlerinin genel olarak doğru olduğunu ancak doğruluğun iyileştirilebileceğini göstermektedir. Sonuçlar, aşağıda tablo[2]'de özetlenmiştir.

Performans Metrikleri	Değerler
MAE	0.4346
MSE	3.777
RMSE	1.9434
R^2	0.6328

Table 2: VGG16 Modelinin Performans Metrikleri

Şekil [2], modelin eğitim ve doğrulama veri setleri üzerindeki kayıp (loss) değerlerini göstermektedir. Grafik, modelin öğrenme sürecindeki performansını değerlendirmek için önemli bilgiler sunmaktadır.

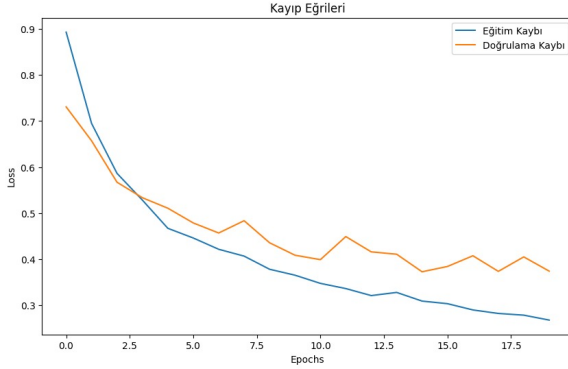


Figure 2: VGG16 Modeli Kayıp Eğrileri

Eğitim kaybı (mavi eğri), modelin eğitim verisi üzerindeki hatasını temsil ederken, doğrulama kaybı (turuncu eğri) modelin doğrulama verisi üzerindeki hatasını göstermektedir. Grafik incelendiğinde şu gözlemler yapılmıştır:

- **Başlangıç Dönemi (Epoch 0-2)** Eğitim ve doğrulama kaybı başlangıçta yüksektir (yaklaşık 1.4). Ancak her iki kayıp değeri de hızla azalmaktadır. Bu, modelin veri setindeki temel yapıları öğrenmeye başladığını göstermektedir.
- **Orta Dönem (Epoch 3-10)** Eğitim kaybı sürekli olarak düşerken, doğrulama kaybı daha az bir hızla azalmaktadır. Bu aşamada model, doğrulama verisinde daha az düzenli bir performans göstermiştir; ancak genel eğilim olumlu yöndedir.
- **Son Dönem (Epoch 10-20)** Eğitim kaybı sürekli azalmaya devam ederken, doğrulama kaybı belirli bir noktada sabitlenmiştir. Eğitim kaybı doğrulama kaybından daha düşük bir değere ulaşmıştır. Bu durum, modelin doğrulama verisi üzerindeki öğrenme sınırına yaklaştığını göstermektedir. Ancak iki kayıp arasında büyük bir fark bulunmaması, modelin

aşırı öğrenim (overfitting) yapmadığını ortaya koymaktadır.

Grafik, modelin eğitim ve doğrulama veri setleri üzerindeki performansını başarılı bir şekilde değerlendirdiğini ve uygun bir genel doğruluk elde ettiğini göstermektedir.

4.3 MobileNetV2 Modeli

Bu çalışmada, MobileNetV2 modeli kullanılarak modelin değerlendirilmesi için Ortalama Mutlak Hata (MAE), Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE) ve Determinasyon Katsayısı (R^2) gibi performans metrikleri hesaplanmıştır. Modelin MAE değeri 0.3942, MSE değeri 3.1676, RMSE değeri 1.7798 ve R^2 değeri 0.692 olarak bulunmuştur. Bu sonuçlar, modelin tahminlerinin genel olarak doğru olduğunu ve VGG16 modeline kıyasla daha iyi bir performans sergilediğini göstermektedir. Sonuçlar, aşağıda tablo[3]'te özetlenmiştir.

Performans Metrikleri	Değerler
MAE	0.3942
MSE	3.1676
RMSE	1.7798
R^2	0.692

Table 3: MobileNet V2 Modelinin Performans Metrikleri

Şekil [3], modelin eğitim ve doğrulama veri setleri üzerindeki kayıp (loss) değerlerini göstermektedir. Grafik, modelin öğrenme sürecindeki performansını değerlendirmek için önemli bilgiler sunmaktadır.

Eğitim kaybı (mavi eğri), modelin eğitim verisi üzerindeki hatasını temsil ederken, doğrulama kaybı (turuncu eğri) modelin doğrulama verisi üzerindeki hatasını göstermektedir. Grafik incelendiğinde şu gözlemler yapılmıştır:

- **Başlangıç Dönemi (Epoch 0-2)** Eğitim kaybı başlangıçta yaklaşık 0.65 değerine sahipken, doğrulama kaybı 0.40 civarındadır. Her iki kayıp değeri de hızla azalmaktadır. Bu durum, modelin veri setindeki temel yapıların öğrenilmesine başladığını göstermektedir.

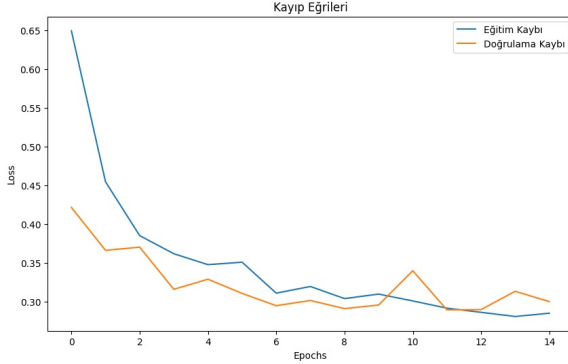


Figure 3: MobileNetV2 Modeli Kayıp Eğrileri

- **Orta Dönem (Epoch 3-10)** Eğitim kaybı sürekli bir şekilde düşerken, doğrulama kaybı daha kararlı bir azalma eğilimi göstermektedir. Bu aşamada modelin öğrenme kapasitesinin doğrulama seti üzerindeki etkileri de iyileşmektedir.
- **Son Dönem (Epoch 10-14)** Eğitim kaybı belirli bir noktada stabil hale gelmiştir ve doğrulama kaybı da benzer şekilde düşük seviyelerde sabitlenmiştir. Eğitim kaybının doğrulama kaybından çok fazla düşük olmaması, modelin aşırı öğrenim (overfitting) yapmadığını göstermektedir.

Grafik, modelin eğitim ve doğrulama veri setleri üzerindeki performansını başarılı bir şekilde değerlendirdiğini ve uygun bir genel doğruluk elde ettiğini göstermektedir.

5 TARTIŞMA VE ÖNERİ

Bu çalışmada, araç görsellerinden yakıt tüketimini tahmin etmek amacıyla Kaggle platformundan elde edilen FuelConsumptionCO2 veri seti [1] ile manuel olarak oluşturulan özel bir veri seti kullanılmıştır. Farklı makine öğrenimi modellerinin araç yakıt tüketimi tahmin performanslarını değerlendirmek için kapsamlı bir analiz gerçekleştirilmiştir. Bu analizde, üç farklı derin öğrenme mimarisi (VGG16, MobileNetV2 ve bir CNN modeli) kullanılmıştır.

Aşağıda, her bir modelin çeşitli performans metriklerine göre elde ettiği sonuçlar sunulmaktadır.

5.1 Performans Karşılaştırması

Her bir modelin performans metrikleri, Ortalama Mutlak Hata (MAE), Ortalama Kare Hata (MSE), Kök Ortalama Kare Hata (RMSE) ve Determinasyon Katsayısı (R^2) değerleriyle özetlenmiştir. Sonuçlar Tablo [4]'te özetlenmiştir.

Model	MAE	MSE	RMSE	R^2
CNN	0.4504	4.0386	2.0096	0.6074
VGG16	0.4346	3.7770	1.9434	0.6328
MobileNetV2	0.3942	3.1676	1.7798	0.6920

Table 4: Modellerin Performans Karşılaştırması

Tablo [4]'te görüldüğü gibi, MobileNetV2 modeli tüm performans metrikleri açısından diğer iki modelden daha iyi sonuçlar elde etmiştir. VGG16 modeli, CNN modeline göre daha iyi performans sergilemiştir, ancak MobileNetV2 kadar etkili değildir. CNN modeli, temel bir yaklaşım olmasına rağmen kabul edilebilir bir performans göstermiştir.

Bu bölümde, her bir modelin avantajları ve dezavantajları çerçevesinde çıkarımlar ele alınmıştır:

- **CNN Modeli:** CNN modeli, temel bir yapıya sahip olması nedeniyle hızlı bir şekilde eğitilmiştir ve makul seviyede bir performans elde etmiştir. Ancak, diğer iki modele göre daha düşük bir R^2 değeri sergileyerek özellikle karmaşık özellikleri öğrenmede yetersiz kalmıştır. Bu durum, modelin daha ileri bir hiperparametre optimizasyonu veya derinleştirilmiş bir mimariye ihtiyacını göstermektedir.
- **VGG16 Modeli:** VGG16 modeli, CNN'e göre daha derin bir mimariye sahip olduğu için daha iyi bir performans sergilemiştir. Ancak, daha büyük bir model olması nedeniyle eğitim süresi daha uzun olmuştur ve hesaplama kaynakları daha yoğun bir şekilde kullanılmıştır. R^2 değeri, modelin doğruluk seviyesinin MobileNetV2 kadar uygun olmadığını göstermektedir.

- **MobileNetV2 Modeli:** MobileNetV2 modeli, hem hızlı eğitim süresi hem de daha iyi tahmin doğruluğu ile öne çıkmıştır. Hafif bir mimariye sahip olması nedeniyle mobil cihazlarda veya sınırlı donanımlarda bile etkili bir şekilde kullanılabilir. Tüm performans metriklerinde en iyi sonuçları elde ederek çalışmanın genel kazananı olarak görülmüştür.

Bu bölüm, her bir modelin performansını ele alarak avantajları ve dezavantajları vurgular. Model seçimi çalışmanın amacına ve uygulama bağlamına göre değişebilir. MobileNetV2, hem performans hem de hesaplama verimliliği bakımından en çok tercih edilebilecek model olmasına rağmen, VGG16 veya CNN gibi modeller de belirli uygulama alanlarında uygun seçenekler olabilir. Bu nedenle, başarı ölçütleri uygulama bağlamına ve veri setine bağlı olarak değişebileceğinden, model seçimi dikkatlice yapılmalıdır.

6 SONUÇLAR

Bu çalışmanın temel çıkarımı, araç görselleri ve sayısal özelliklerini birleştiren veri setleri ile derin öğrenme modellerinin yakıt tüketimi tahmininde başarılı bir şekilde kullanılabileceğidir. Çalışmada MobileNetV2, VGG16 ve CNN modelleri kullanılmış ve MobileNetV2, tüm performans metriklerinde en iyi sonuçları elde ederek bu alandaki potansiyelini ortaya koymuştur. Bu başarı, derin öğrenme modellerinin sadece tahmin doğruluğu sağlamakla kalmayıp, aynı zamanda yakıt tüketimi tahmini gibi kritik bir alanda önemli karar destek mekanizmaları sunabileceğini göstermektedir.

Araçların yakıt tüketiminin doğru tahmini, hem bireysel hem de toplumsal düzeyde yakıt verimliliğini artırmak için stratejik bir öneme sahiptir. Yakıt tüketimi tahmini, üreticilerin daha verimli araçlar tasarlamasına, kullanıcıların yakıt ekonomisi konusunda bilinçlenmesine ve hükümetlerin çevresel düzenlemelere uygun politikalar geliştirmesine olanak tanır. Bu çalışmada kullanılan modeller, özel-

likle MobileNetV2'nin hafif yapısı sayesinde sınırlı donanım kaynaklarına sahip sistemlerde gerçek zamanlı analizler için kullanılabilir. Bu da araç kullanıcılarının, sürüş davranışlarını optimize ederek yakıt tasarrufu sağlamalarına ve karbon emisyonlarını azaltmalarına yardımcı olabilir. Çalışmanın diğer önemli bir çıkarımı, yakıt verimliliğini artırmak için kullanılan yöntemlerin genişletilebilir ve farklı uygulamalara uyarlanabilir olduğudur. Örneğin, araç filoları için bu tür tahmin modelleri, operasyonel maliyetleri düşürmek, çevresel etkileri azaltmak ve filo yönetim stratejilerini optimize etmek için kullanılabilir. Ayrıca, gelecekte daha büyük ve zengin veri setleri ile hibrit modellerin veya ileri hiperparametre optimizasyon tekniklerinin kullanılması, tahmin performansını daha da artırabilir.

Sonuç olarak, bu çalışma, yakıt tüketimi tahmininde derin öğrenme modellerinin etkinliğini ve bu alandaki potansiyel uygulamalarını göstermiştir. Özellikle MobileNetV2 modeli, yakıt tüketimi tahmininde yüksek doğruluk ve verimlilik sunarak hem bireysel kullanıcılar hem de sektörel uygulamalar için bir rehber niteliği taşımaktadır. Bu tür teknolojilerin geliştirilmesi, sürdürülebilir ulaşım hedeflerine ulaşmada ve çevresel etkilerin azaltılmasında önemli bir rol oynayabilir.

KAYNAKÇA

- [1] Ramlal Naik. *FuelConsumptionCO2*. Kaggle dataset. 2024. URL: <https://www.kaggle.com/datasets/ramlalnaik/fuelconsumptionco2>.